פרויקט קורס

למידת מכונה – חלק א'

קבוצה 5

מגישות:

ליה רוזן

עופרי רטינסקי

1. Data collection and Sensing

- Data Collection הוא השלב שבו נאספים נתונים רלוונטיים מתוך העולם האמיתי, במטרה ללמד את המודל לבצע משימה מסוימת. במקרה שלנו, הנתונים כוללים פוסטים שנכתבו ברשת החברתית (X).

סוג ה-Sensing שבוצע הוא סטטי, מפני שהנתונים נאספו בנקודת זמן אחת ואינם משתנים - לדוגמה, מספר הלייקים שניתנו לפוסט נמדד חודש לאחר פרסום הפוסט וכך גם מספר השיתופים שקיבל הפוסט. כלומר, אין מעקב רציף על הערכים הללו לאורך זמן.

- סוג Sensing שלא בוצע הוא חישה דינמית – (Dynamic Sensing) כלומר איסוף נתונים שמשתנים לאורך זמן, ולא רק בנקודת זמן אחת. לדוגמה, ניתן היה לעקוב אחרי קצב הלייקים והשיתופים שהפוסט מקבל בכל יום במהלך החודש, ולא רק לקבל את המספר הסופי. חישה דינמית הייתה מאפשרת לנתח מגמות, לזהות פוסטים ש"הפכו לוויראליים" באיחור, ולשפר את איכות המאפיינים שנשתמש בהם לאימון המודל.
- קטגוריית משימת הלמידה היא למידה מונחית (Supervised Learning) מאחר ולכל דוגמה בדאטה יש תווית (label) ברורה של סנטימנט – חיובי או שלילי.

סוג המשימה הוא סיווג (Binary Classification), כי המטרה היא ללמד את המודל לזהות לאיזו קטגוריה שייכת כל הודעה - לקבוע האם הסנטימנט של ההודעה הוא חיובי או שלילי. בנוסף, ניתן להשתמש באותו הדאטה גם למשימות אחרות. לדוגמה, משימת חיזוי רגרסיה – (Prediction Regression) ניתן לנסות לחזות את מספר הלייקים או השיתופים שפוסט יקבל, על בסיס טקסט ההודעה ופרטי המשתמש.

2. Exploratory data analysis

הדאטה סט שקיבלנו מכיל כ- 40,000 הודעות שסווגו לפי סנטימנט: חיובי או שלילי. תחילה נבדוק את התפלגות משתנה המטרה, Sentiment, על מנת לראות האם סט הנתונים מאוזן. ונמשיך לבדוק את התפלגות כל המשתנים הנתונים לנו בדאטה סט.

<u>משתנה המטרה Sentiment-</u>

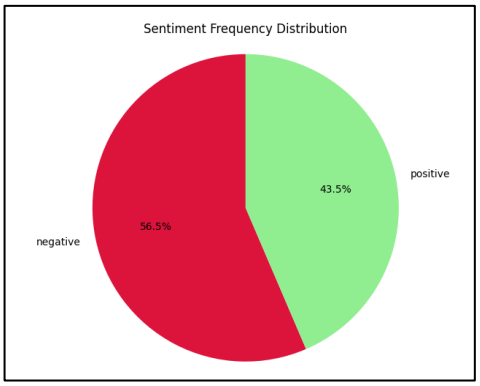

משתנה זה הוא משתנה בוליאני שבודק האם ההודעה היא חיובית או שלילית. קיבלנו כי המשתנה כמעט מאוזן ,מהנתונים אפשר לראות כי כ-56.5% מכלל הודעות הן שליליות (22285), ו43.5% הן חיוביות (17188).

משתנה id-

משתנה זה הינו מזהה ייחודי של ההודעה, כל הודעה מקבלת id ייחודי לה ולכן אין מה להסיק ממשתנה זה.

משתנה username-

זהו שם המשתמש של מפרסם ההודעה. בעזרת משתנה זה ניתן לבדוק בדרכים שונות את הקשר לסנטימנט כגון: האם שם המשתמש ארוך וכולל תווים רבים שאינם אותיות או האם שם המשתמש תואם לאימייל. דברים אלו יכולים להעיד על חשבונות פיקטיביים, חשבונות אלו נוטים יותר לפרסם הודעות שליליות.

משתנה text-

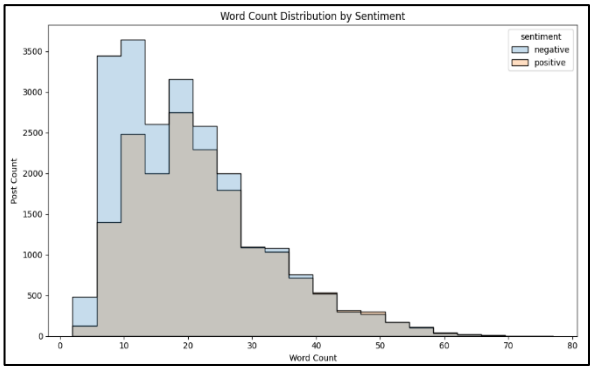

משתנה זה מייצג את תוכן ההודעה. יצרנו גרף המראה את התפלגות אורך ההודעה (כמות המילים) לכל סנטימנט, ראינו כי טווח הערכים הוא 2-77 מילים ושממוצע המילים בהודעה הוא 21. לפי הגרף נראה כי ההתפלגות של מספר המילים בהודעה היא התפלגות פואסונית. תוכן ההודעה יכול להעיד רבות על סוג הסנטימנט שלה שכן הוא מכיל את המידע הרגשי שלה. ניתן לבצע עליו טרנספורמציות שונות כגון: בדיקת מילים נפוצות בכל סנטימנט, בדיקת כמות האשטגים או סימני קריאה ועוד.

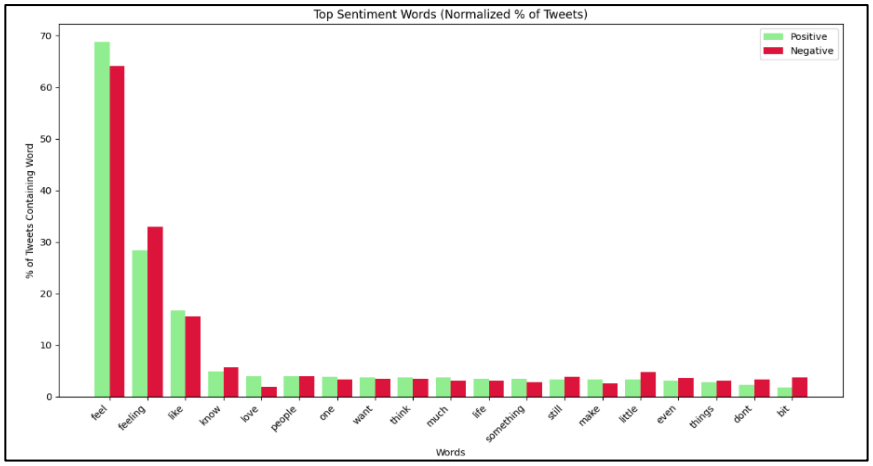

משתנה type-

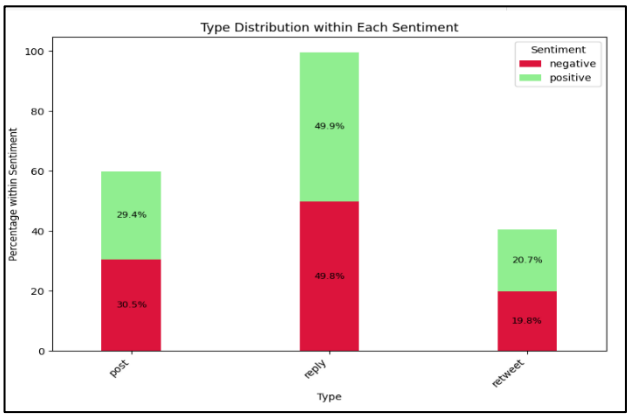

משתנה זה מציין את סוג ההודעה - פוסט מקורי, תגובה או שיתוף. לסוג ההודעה יכולה להיות השפעה על תוכן רגשי – למשל, תגובות נוטות להיות ישירות יותר, מה שעשוי להשליך על הסנטימנט. ניתן לראות שתגובות מהוות פלח משמעותי יותר מכלל ההודעות, ומכילות שיעור גבוה של הודעות שליליות יחסית לפוסטים ושיתופים. זה עשוי להצביע על כך שתגובות

משקפות רגשות חזקים יותר, מה שמחזק את חשיבותו של המשתנה במודל הסיווג לסנטימנט.

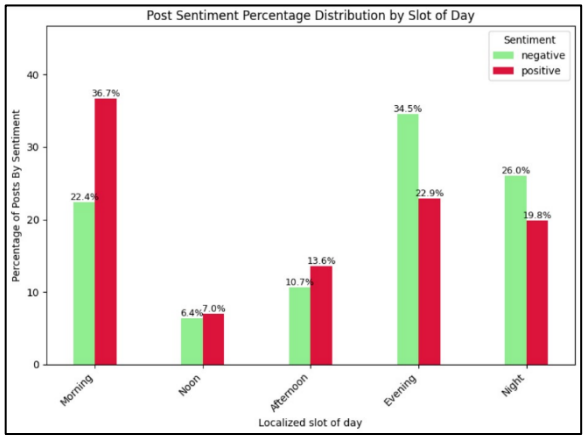

משתנה post_datetime ו-Timezone -

משתנים אלו מייצגים את תאריך וזמן שליחת ההודעה ואזור הזמן. בעזרת משתנים אלו יצרנו את חלון הזמן בו פורסמה ההודעה לפי אזור הזמן שלו. ניתן לראות שהתפלגות הסנטימנטים משתנה לאורך שעות היום, כאשר בערב נרשם שיעור גבוה יותר של הודעות חיוביות, ובבוקר ובלילה שיעור גבוה יותר של הודעות שליליות, מה שמצביע על השפעה אפשרית של מצב הרוח של המשתמשים בשעות שונות על סנטימנט ההודעות. בנוסף, ניתן לסווג את תאריך שליחת ההודעה לימים בכדי לבדוק קשר לסנטימנט, ייתכן כי לימים מסוימים ישנם השפעה על ערך הסנטימנט.

משתנה post_likes-

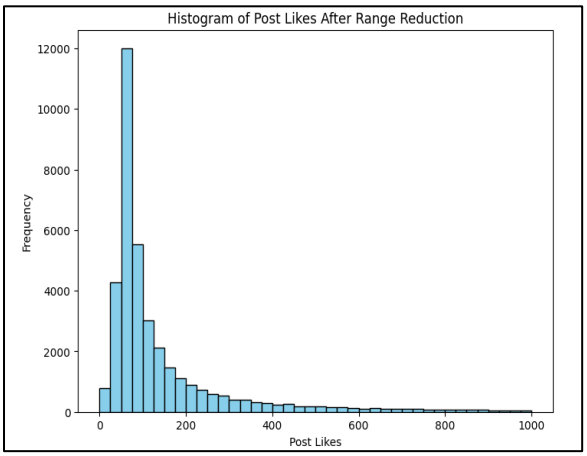

משתנה זה מציין את מספר הלייקים שהפוסט קיבל לאחר חודש מפרסומו. טווח הערכים של משתנה זה הוא -20 29,508 לייקים. ראינו כי הממוצע הוא 350 והחציון הוא 85 ולכן צמצמנו את הטווח בין 0-1000. ההתפלגות של משתנה זה היא התפלגות לוג-נורמלית שהיא בעלת זנב ימני ארוך ומתאימה למשתנים חיוביים המוגבלים מלמטה ב-0. בהקשר למשימת הלימוד כמות הלייקים יכולה לשמש כאינדיקטור לרמת המעורבות או ההשפעה של הפוסט. ייתכן שפוסטים בעלי סנטימנט חיובי מקבלים יותר לייקים, ולכן המשתנה עשוי לסייע בניבוי הסנטימנט. בעזרת משתנה זה נוכל להוציא מידע נוסף על פופולריות ההודעה בעזרת טרנספורמציות שונות עם משתנים של כמות השיתופים ומספר העוקבים וכך לגלות קשרים חזקים יותר למשתנה המטרה.

משתנה email-

משתנה זה מציין את האימייל שבאמצעות נרשם המשתמש. משתנה זה לבדו אינו מוסיף מידע על הסנטימנט אך בשילוב כמו שהוסבר במשתנה username יוכל להוסיף מידע.

משתנה post_retweets-

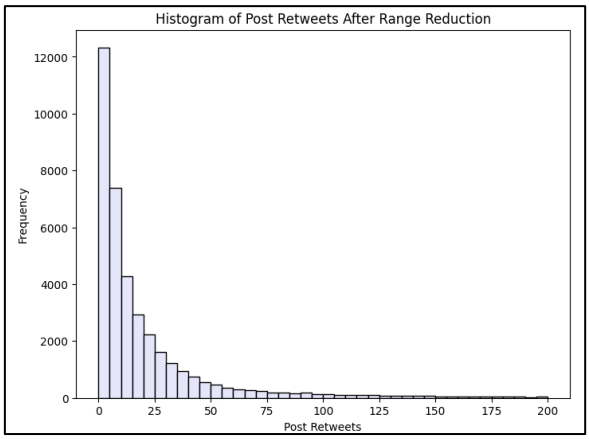

משתנה זה מציין את מספר השיתופים שהפוסט קיבל לאחר חודש מפרסומו. במשתנה זה טווח הערכים הינו 0- 16,679 והתפלגותו היא אקספוננציאלית. גם במשתנה זה קיבלנו ערכים חריגים ולכן צמצמנו את הטווח בין 0-1000. כמות השיתופים יכולה להעיד רבות על סנטימנט ההודעה, ייתכן שאנשים נוטים לשתף יותר הודעות חיוביות ומבדרות מאשר הודעות פוגעניות ולא נעימות.

משתנה embedded_content_url-

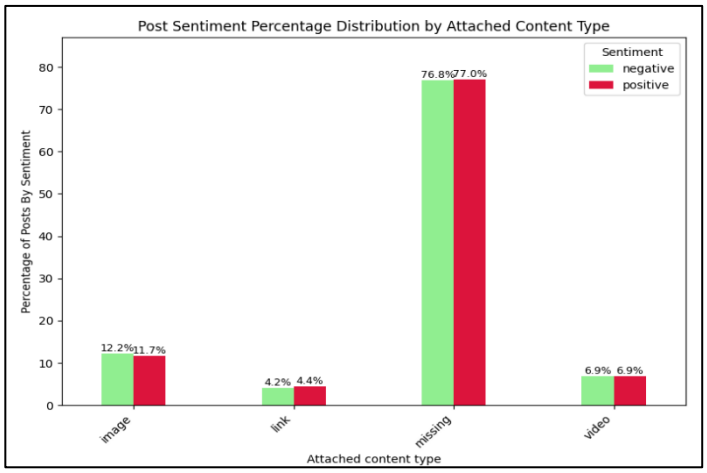

משתנה זה מציין את התוכן המצורף להודעה. ממשתנה זה בדקנו את סוג התוכן המצורף להודעה - תמונה, וידיאו, לינק וכו'. ניתן לראות לפי הגרף כי סוג הקובץ המצורף להודעה לא מעיד על סוג הסנטימנט בצורה ברורה. בעזרת ביצוע מניפולציות על משתנה זה, נוכל לבחון קשרים פוטנציאליים עם משתנה המטרה. ניתן לבדוק את השילוב בין סוג הקובץ המצורף להודעה לבין קיומה של תמונת פרופיל. פרסום הודעה הכוללת קישור חיצוני על ידי משתמשים אשר אינם מציגים תמונת פרופיל עשוי לרמז על הטיה סנטימנטלית שלילית בתוכן. היעדר חשיפה אישית של המשתמש עלול להפחית את תחושת האחריות והפגיעות שלו מהשלכות פרסומיו, ובכך לעודד הפצה של תכנים בעלי סנטימנט שלילי.

משתנה checkmark-

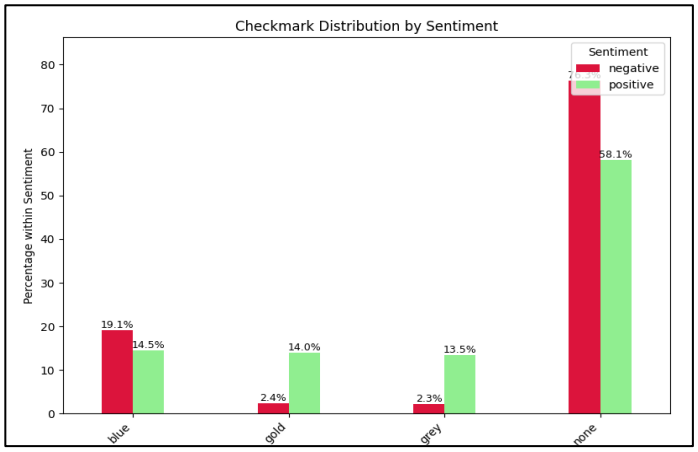

משתנה קטגוריאלי זה מייצג את סוג החשבון – פרטי, פרמיום, רשמי של ארגון או רשמי של ממשלה. סוג החשבון יכול לרמז על סנטימנט ההודעה. הודעות שליליות רבות מגיעות מחשבונות לא מאומתים, שכן כל אחד יכול ליצור חשבון כזה ולא נעשית עליו בדיקה לפני פרסום הודעות. חשבונות מאומתים, המייצגים גופים או אינדיבידואלים שעברו בדיקה, עשויים לפרסם הודעות חיוביות יותר מפני שיש להם אחריות גדולה יותר לתוכן המפורסם. בנוסף, ניתן לבדוק שילוב של סוג החשבון עם קיום או העדר תמונת פרופיל דבר שיכול גם כן להעיד על חשבונות פיקטיביים.

משתנה account_creation_date-

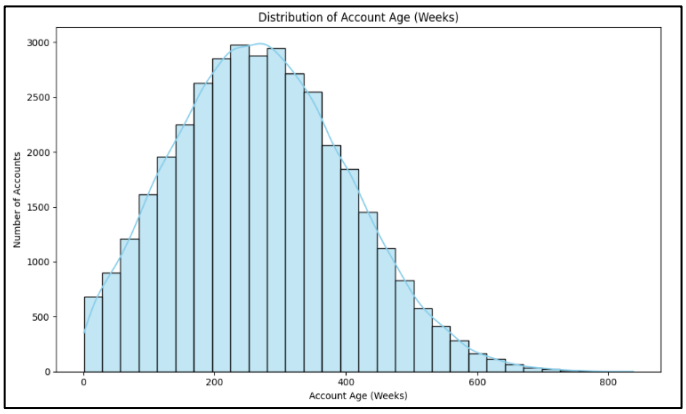

משתנה זה מציין את תאריך יצירת החשבון. ממשתנה זה בדקנו את גיל החשבון בשבועות בעת פרסום הפוסט. טווח הערכים של גילאי החשבונות הוא 1-838 שבועות וההתפלגות שלו היא נורמלית עם סטיית תקן 131.461 וממוצע 271.925. גיל החשבון יכול לספק מידע על אמינות, ותק והתנהגות משתמשים, שעשויים להיות קשורים לסנטימנט ההודעות שלהם. חשבונות חדשים או ותיקים מאוד יכולים להיות קשורים יותר לסנטימנט מסוים. בנוסף, ניתן ליצור טרנספורמציות עם משתנה זה יחד עם מספר העוקבים של המשתמש או עם מספר פוסטים קודמים שיראו את פעילות החשבון וצמיחתו.

משתנה profile_picture_url-

משתנה זה מייצג את הקישור לתמונת הפרופיל. כמשתנה בינארי, הוא עשוי לתרום לניתוח הסנטימנט, שכן היעדר תמונת פרופיל מאפיין לעיתים קרובות חשבונות פיקטיביים. מוסבר לעיל על שילובים אפשריים עם משתנה זה.

משתנה birthday-

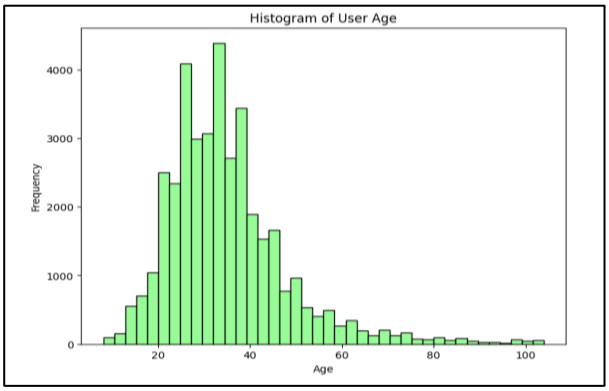

זהו תאריך הלידה של המשתמש. ממשתנה זה ומתאריך פרסום ההודעה יצרנו את גיל המשתמש בעת הפרסום. טווח הערכים של גילאי המשתמשים הוא בין 8-104 שנים והתפלגות היא נורמלית עם סטיית תקן 13.27 וממוצע 34.824.

גיל המשתמש יכול לתרום להבנת סנטימנט ההודעה, שכן קבוצות גיל שונות עשויות להשתמש בסגנונות שפה וביטויי רגשות שונים ברשתות החברתיות ואף להיות מעורבים בטרנדים, מה שיכול להשפיע על הסנטימנט ההודעה.

משתנה followers-

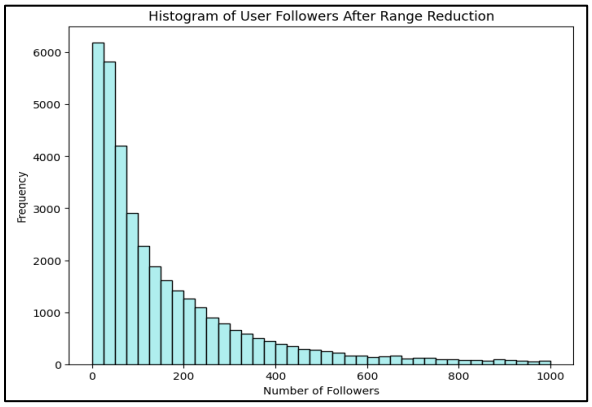

משתנה זה מייצג את מספר העוקבים של המשתמש בעת פרסום הפוסט. טווח הערכים של המשתנה הוא 0-120,692 עוקבים. במשתנה זה קיבלנו ערכים חריגים ולכן צמצמנו את הטווח בין 0-1000. התפלגות המשתנה היא לוג-נורמלית.

מספר העוקבים יכול לשמש כאינדיקטור עקיף לסנטימנט, שכן משתמשים בעלי השפעה רבה או פרופילים שונים, כמו משפיענים או קמפיינים, עשויים להציג דפוסי סנטימנט ייחודיים בהשוואה למשתמשים עם מספר עוקבים מועט. בנוסף, ניתן ליצור טרנספורמציות עם משתנה זה יחד עם מספר הפוסטים שהמשתמש פרסם בכדי לראות את קצת גדילת החשבון.

משתנה previous_posts_count-

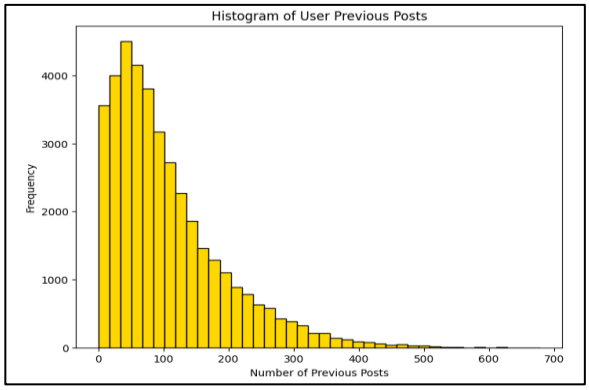

משתנה זה מציין את מספר הפוסטים שפרסם המשתמש עד ליום פרסום ההודעה. טווח הערכים של המשתנה הוא 0-679 והתפלגותו היא אקספוננציאלית. משתנה זה יכול להוות אינדיקטור עקיף לסנטימנט, שכן משתמשים בעלי היסטוריית פרסום ענפה עשויים להיות בעלי סגנון כתיבה מגובש יותר או מעורבות גבוהה יותר בפלטפורמה, מה שיכול להשפיע על הטון והרגש בהודעותיהם, זאת בניגוד למשתמשים חדשים או פחות פעילים.

חשיפת קשרים בין משתנים:

קורלציה בין המשתנים הקטגוריאליים-

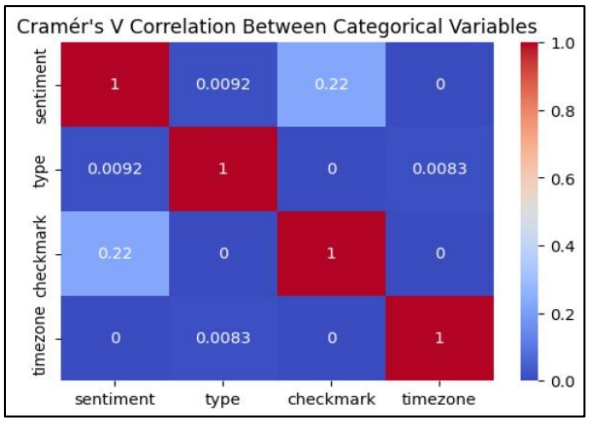

בכדי לבחון את הקשרים בין משתנים אלו יצרנו מטריצת קורלציה בין המשתנים timezone, checkmark, type ו- sentiment. ניתן לראות כי הקורלציה בין רוב המשתנים היא אפסית, כלומר הם אינם מסבירים אחד את השני. בין הsentiment לcheckmark ישנה קורלציה חיובית מה שמעיד על קשרה חיובי חלש ביניהם.

קורלציה בין המשתנים הנומריים-

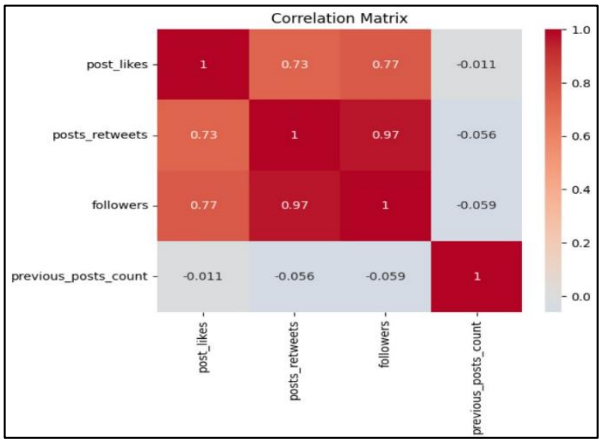

יצרנו מטריצת קורלציה נוספת בין המשתנים post_likes, post_retweets, followers ו- previous_posts_count. ניתן לראות כי הקורלציה בין המשתנים post_likes, post_retweets, followers יחסית גבוהה, כלומר משתנים אלה מסבירים זה את זה. לעומת זאת, במשתנה previous_posts_count רואים קורלציה כמעט אפסית, כלומר הוא אינו מסביר באופן משמעותי את השינויים במשתנים האחרים.

3. <u>Dataset creation</u>

– Pre-Processing

מטרתו העיקרית של שלב זה היא לשפר את ההפרדה בין הקטגוריות השונות ולייצג את הנתונים בצורה מיטבית שתאפשר לישות להיות מאופיינת באופן מדויק יותר. במהלך שלב זה, נבצע פעולות שונות על הנתונים הגולמיים, כך שהאלגוריתם הלומד יוכל לנצל בצורה יעילה את המאפיינים הרלוונטיים שנאספו בשלב החישה וללמוד מהם.

טיפול בחזרתיות - ראינו כי בדאטה סט אין שתי רשומות שחוזרות על עצמן לכן אין חזרתיות.

טיפול בערכים חסרים – תחילה הסרנו ערכים חריגים ממערך הנתונים. פעולה זו נועדה למנוע overfitting של המודל ל training set. לצורך כך, יישמנו את שיטת ה- IQR. בנוסף, זיהינו כ-480 דגימות בהן קיימים 8 ערכים חסרים. רשומות אלה הוסרו במלואן ממערך הנתונים, זאת מתוך הנחה כי השלמת מספר כה רב של ערכים חסרים באמצעות שיטות סטטיסטיות עלולה לעוות את הייצוגיות של הנתונים ולפגוע במהימנותם. בהמשך לכך, עבור כל משתנה, נבחן את האסטרטגיה המתאימה ביותר לטיפול בערכים החסרים שנותרו.

Sentiment – ממשתנה המטרה הסרנו רשומות עם ערכים חסרים. זאת מכיוון שאימון מודל לביצוע משימת סיווג מחייב קיומה של תווית (label) מוגדרת עבור כל אחת מהישויות.

עבור המשתנים הקטגוריאליים timezone, checkmark, type ו-sentiment - במשתנים אלו השלמנו את הערכים החסרים על ידי ייחוסם מחדש בהתאם להתפלגות ההסתברותית של הקטגוריות הקיימות. גישה זו נועדה לשמר את מאפייני המשתנה ולהימנע מהטיה, תוך הקצאת ערכים חסרים באופן פרופורציונלי לשכיחות הקטגוריות.

עברו המשתנים הנומריים post_likes, post_retweets, followers ו-
previous_posts_count - במשתנים הללו השלמנו את הערכים החסרים באמצעות החציון, מכיוון שרוב המשתנים לא התפלגו נורמלית. החציון, כמדד מרכז שאינו רגיש לערכים קיצוניים, עוזר לשמור על פיזור הנתונים ולמנוע הטיה.

המרת סוגי משתנים –

מהמשתנים timezone ו- post_datetime חילצנו את התאריך והשעה המדויקים שהמשתמש חווה. קראנו למשתנה זה localized_date_time.

ממשתנה post_datetime חילצנו את החודש בו פורסמה ההודעה. קראנו למשתנה זה month_of_post.

- Feature Extraction

חילוץ תכונות הוא תהליך טרנספורמציה של הנתונים הגולמיים, שמטרתו לייצר ייצוג חדש וקומפקטי יותר של המידע. במסגרת פעולה זו, קבוצת המאפיינים המקורית עוברת מיפוי למרחב מאפיינים חלופי. שינוי זה נועד לייעל את אופן ייצוג הנתונים בהשוואה למבנה המקורי. השאיפה היא להפיק מהדאטה הגולמי מאפיינים כלליים ורלוונטיים, כאשר כל מאפיין שנוצר מהווה מועמד פוטנציאלי להזנת מודל הלמידה.

1. **region:**מיפינו את אזור הזמן לאזור גיאוגרפי באמצעות מילון שהוגדר מראש.
2. **day_of_week**: לאחר המרת התאריך לשעה המקומית, חילצנו את היום בשבוע מתוך ה-post_datetime.
3. **age:** חישבנו את גיל המשתמש לפי תאריך הלידה ביחס לתאריך פרסום הפוסט.
4. **localized_slot_of_day:** לאחר המרת התאריך לשעה המקומית, חילקנו את שעות היום לחלונות זמן: 06:00-12:00 – Morning, 12:00-14:00 – Noon, 14:00-18:00 – Afternoon, 18:00-23:00 – Evening, 23:00-06:00 – Night.
5. **daily_retweet_rate:** חישבנו את שיעור השיתופים היומי של פוסט על ידי חלוקת מספר השיתופים ב-30.
6. **account_seniority_weeks:** חישבנו את הותק של חשבון המשתמש בשבועות, לפי תאריך יצירת החשבון לעומת תאריך הפוסט.
7. **posts_per_week:** חישבנו את מספר הפוסטים של המשתמש ביחס לוותק החשבון בשבועות.
8. **followers_per_week:** חישבנו את כמות העוקבים של המשתמש ביחס לוותק החשבון בשבועות.
9. **followers_to_previous_posts:** חישבנו את יחס מספר העוקבים לעומת מספר הפוסטים הקודמים של המשתמש.
10. **likes_to_retweets_rate:** חישבנו את יחס הלייקים לשיתופים עבור כל פוסט.
11. **likes_to_followers_rate:** חישבנו את יחס הלייקים לעוקבים עבור כל פוסט.
12. **text_word_count:** חישבנו את מספר המילים בכל פוסט.
13. **hashtag_count:** חישבנו את מספר ההאשטאגים (#) בכל פוסט.

14. **attached_content_type:** סיווגנו את סוג התוכן המצורף לכל פוסט, כמו תמונות, סרטונים או קישורים, בהתאם ל-embedded_content_url.

15. **user_has_profile_picture:** קבענו אם למשתמש יש תמונת פרופיל, בהתבסס על קיומה של תמונה בכתובת ה-profile_picture.

16. **attached_content_and_picture_status:** שילבנו את סוג התוכן המצורף עם הסטטוס של תמונת פרופיל.

17. **profile_picture_and_checkmark_status:** שילבנו את סטטוס תמונת הפרופיל עם סוג החשבון.

18. **similar_domain_and_picture:** יצירה של משתנה המשלב את סטטוס תמונת הפרופיל עם אם שם המשתמש מופיע בכתובת האימייל.

19. עבור הפיצ'רים הנומריים, הפעלו פונקציית log כדי לטפל בערכים גבוהים.

20. כדי לנתח את המשתנה text, השתמשנו בשיטת N-gram לחילוץ מילים וצמדי מילים שעשויים להיות קשורים לסנטימנט של ההודעה. מכיוון שהטקסט כולל מילות קישור, בחרנו קודם לנקות אותו באמצעות הסרת מילות stop words. לאחר מכן, השתמשנו בשיטת TFIDF כדי לנתח את הטקסט ולחלץ את המילים והצמדים המשמעותיים ביותר. מתהליך זה חילצנו 42 פיצ'רים נוספים, כאשר 23 מתוכם הם צמדי מילים.

– Feature Representation

בשלב זה, לאחר שקבענו את רשימת הפיצ'רים, אנו מבצעים נרמול של ערכי כל פיצ'ר כך שיימצאו בטווח אחיד בין 0 - 1. מטרת הנרמול היא להבטיח שלכל פיצ'ר תהיה תרומה שווה בתהליכי החישוב של המודל.

את כל הפיצ'רים הקטגוריאליים המרנו לפיצ'רים בינאריים חדשים באמצעות שימוש בפונקציה get dummies. כל ערך ייחודי בכל קטגוריה הופך לפיצ'ר חדש עם ערכים של 0 או 1, המציינים את קיומו או היעדרו של הערך בדגימה.

את השינוי של סקאלת הפיצ'רים הנומריים, הקוד מיישם באמצעות Min-Max. פעולה זו מנרמלת את הנתונים לטווח בין 0 ל-1. שיטה זו יוצרת סטנדרטיזציה של הנתונים על פני טווח הערכים שלהם (מהמינימום למקסימום), ובכך מסייעת להשוות את תרומת הפיצ'רים השונים במהלך הניתוח, ללא תלות בסדרי הגודל המקוריים שלהם.

– Feature selection

בשלב בחירת הפיצ'רים, שאפנו לצמצם את מספר המאפיינים המוזנים לאלגוריתם הלמידה, תוך שמירה על סט מצומצם אך בעל ערך אינפורמטיבי גבוה. מטרתנו הייתה לספק למודל מאפיינים המייצגים בצורה מיטבית את הדגימות ומאפשרים הבחנה ברורה בין הודעות חיוביות לשליליות. כדי להשיג זאת, ביצענו הערכה כמותית של כלל המאפיינים הקיימים, במטרה לקבוע את מידת הרלוונטיות שלהם להבחנה בין הקלאסים. לצורך הערכה זו, בחרנו להשתמש בגישת ה-Filters, ובפרט בשיטת Fisher Score. מתוך 110 הפיצ'רים שיצרנו, בחרנו להישאר עם 22 הפיצ'רים בעלי ערכי ה-Fischer Score הגבוהים ביותר, שלא חוזרים על עצמם מבחינת לוגים או הפכים בקטגוריאליים, מתוך הנחה שהם בעלי יכולת ההבחנה הגבוהה ביותר.

- Dimensionality reduction

בשלב צמצום המימדיות, מטרתנו היא להקטין את מספר הפיצ'רים במערך הנתונים תוך שמירה על מרבית המידע הרלוונטי. צמצום זה מסייע בשיפור יעילות החישוב, הפחתת רעשים וצמצום הסיכון להתאמת יתר. קיימות שיטות שונות להשגת מטרה זו כגון PCA, אך בפרויקט שביצענו, לאחר שעשינו את תהליך ה- Feature Selection בו נבחרו 22 הפיצ'רים המשמעותיים ביותר, ולא נותר עודף מימדים בולט, החלטנו שלא ליישם שלב נוסף של צמצום המימדיות.

4. **Validation** –

בחרנו להעריך את ביצועי המודל באמצעות k-fold Cross-Validation. שיטה זו מחלקת את מערך הנתונים ל k-חלקים שווים ומאמנת את המודל על k-1 מהחלקים, והחלק הנותר משמש כסט בדיקה. תהליך זה חוזר על עצמו k פעמים, כך שכל חלק מהנתונים משמש כסט בדיקה פעם אחת. יתרון מרכזי של שיטה זו הוא הפחתת השונות בהערכת הביצועים, מכיוון שהמודל נבדק על תתי-קבוצות שונות של הנתונים. בנוסף, היא מאפשרת שימוש יעיל יותר בכלל הנתונים וסיוע במניעת overfitting. עבור משימת הסיווג שלנו, נשתמש במדד Recall, המודד את שיעור המקרים החיוביים שזוהו נכון מתוך כל המקרים החיוביים.