פרויקט חיזוי סנטימנט - חלק ב'

קורס למידת מכונה 364-1-1811 | סמסטר ב' תשפ"ה

אימון ובחינה של מודלי למידת מכונה

מגישות:

ליה רוזן

עופרי רטינסקי

תוכן עניינים

.0 הקדמה..... 1

.1 Model Training.....1

.1.1 Decision Trees.....1

.1.2 Artificial Neural Networks.....3

.1.3 SVM.....5

.1.4 Clustering.....6

.2 Evaluation.....8

.3 Improvements.....9

.4 Test.....10

0. הקדמה

לצורך האימון השתמשנו ב-Stratified K-Fold Cross-Validation (עם K=10), כך שיחס המחלקות נשמר בכל חלוקה, ועם random_state=42 לשמירה על עקביות. כדי להימנע מזליגת נתונים, כל נרמול בוצע מחדש בכל קיפול על סט האימון בלבד. ערכים חסרים מולאו לפי חציון והתפלגות על כלל הדאטה - שיטה שעלולה לכלול זליגה מסוימת. מדובר בהנחה מגבילה שאנחנו מודעות לה.

1. Model Training

1.1. Decision Trees

א. אימון וכוונון היפר-פרמטרים:

נציג תחילה עץ החלטה עם פרמטרים שרירותיים לשם ויזואליזציה ותפיסה ראשונית:

קריטריון: אנטרופיה, עומק מקסימלי: 5, מתוכן 3 רמות מוצגות לשם פשטות הפלט

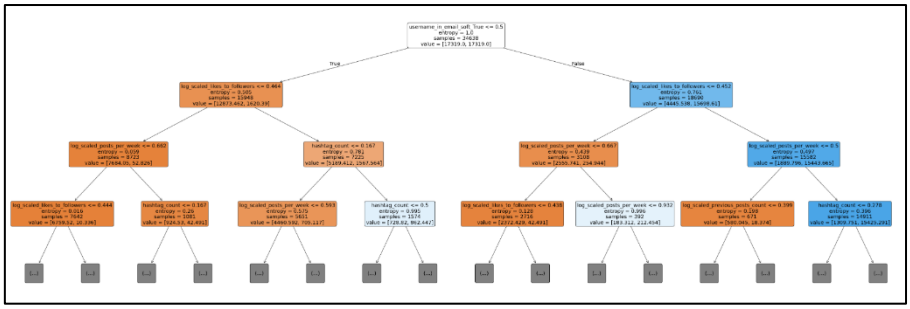

```
Average AUC Score for Validation Set: 0.9721920977618849
Average AUC Score for Training Set: 0.9734798501826593
```

במהלך בניית מודל עץ ההחלטה זיהינו הטיה כלפי המחלקה השלילית (Negative), כפי שניכר מדומיננטיות הצבע הכתום בעץ. כדי להתמודד עם חוסר האיזון בין המחלקות בנתוני האימון, השתמשנו בפרמטר class_weight='balanced', שמעניק משקל גבוה יותר למחלקה הפחות שכיחה וכך משפר את יכולת ההבחנה של המודל. סט הוולידציה נותר לא מאוזן בכוונה, כדי לשקף ביצועים בעולם האמיתי. לשיפור המודל, בוצע כוונון היפר-פרמטרים בעזרת Grid Search שכלל קרוס-ולידציה עם 10 קפלים והערכה לפי AUC. בשונה מ-Random Search, גישת חיפוש יסודית זו מתאימה כשמרחב הפרמטרים מצומצם ונדרש מיצוי מלא של האפשרויות.

הפרמטרים שנבדקו בתהליך:

- **פונקציית הפיצול של העץ (criterion):** נבדקו: "gini", "entropy".
  פונקציה זו קובעת את הקריטריון שלפיו מחולק כל צומת בעץ. ג'יני הוא מדד פשוט ואינטואיטיבי לטוהר הקבוצות, ואילו אנטרופיה מבוססת על תורת המידע. שניהם שואפים לפיצולים שמובילים להומוגניות גבוהה ככל האפשר.
- **העומק המרבי של העץ (max_depth):** נבדקו ערכים מ-1 עד 20, בקפיצות של 1.עצים עמוקים קולטים מורכבות רבה יותר, אך בסיכון ל- overfitting. מתוך התבוננות בעץ השרירותי ראינו שכבר ברמה השלישית כמות התצפיות בצמתים קטנה מאוד, ולכן טווח הבדיקה נשאר מצומצם.

- **מספר מינימלי לפיצול צומת (min_samples_split):** ערכים מ-100 עד 1000, בקפיצות של 50. פרמטר זה קובע את הדרישה המינימלית למספר תצפיות בצומת כדי לאפשר פיצול נוסף. ערכים גבוהים יותר יוצרים עצים פשוטים יותר עם פחות פיצולים, וכך מסייעים למנוע overfitting.
- **משקל המחלקות (class_weight):** ערכים שנבדקו: "None", "balanced"
כפי שצוין לעיל, פרמטר זה משנה איך המודל עצמו מתייחס לכל מחלקה בזמן האימון.

תוצאות:

הפרמטרים שנבחרו הם:

- **קריטריון:** אנטרופיה
- **העומק המקסימלי של העץ:** 14
- **המספר המינימלי של תצפיות הנדרש כדי לפצל צומת:** 250
- **משקל המחלקות:** None

	param_clf__criterion	param_clf__class_weight	param_clf__max_depth	param_clf__min_samples_split	mean_test_score	rank_test_score
630	entropy	None	14	250	0.986157	1
1390	entropy	balanced	14	250	0.986112	2
611	entropy	None	13	250	0.986106	3
1371	entropy	balanced	13	250	0.986076	4
1389	entropy	balanced	14	200	0.986047	5
...	...	...	...	...	...	...
389	entropy	None	1	550	0.824840	1445
386	entropy	None	1	400	0.824840	1445
18	gini	None	1	1000	0.824840	1445
17	gini	None	1	950	0.824840	1445
16	gini	None	1	900	0.824840	1445

במהלך חיפוש הפרמטרים האופטימליים, חושבו ערכי AUC הן לסט האימון והן לסט הולידציה. ממוצע ה-AUC על סט האימון עמד על 0.99, בעוד שממוצע ה-AUC על סט הולידציה היה 0.9862. הפער הקטן ביניהם מעיד על כך שהמודל מצליח ללמוד תבניות כלליות בצורה טובה מבלי להיגרר ל- overfitting.

```
AUC Scores per Fold:
   Fold  Train AUC  Validation AUC
0     1   0.990004        0.988207
1     2   0.989673        0.984792
2     3   0.990093        0.985587
3     4   0.989636        0.986318
4     5   0.990218        0.984954
5     6   0.989853        0.987977
6     7   0.990012        0.985909
7     8   0.990103        0.986179
8     9   0.990100        0.987842
9    10   0.990093        0.983809
Average AUC Scores:
Mean AUC on Training Set:   0.9900
Mean AUC on Validation Set: 0.9862
```

ב. פירוש והבנת המודל:

בהקשר של חיזוי סנטימנט, במיוחד בנושאים רגישים כמו בריאות הנפש, ליכולת הפירוש של עץ החלטה חשיבות רבה, שכן היא מאפשרת להבין אילו פיצ'רים הובילו לחיזוי, לזהות טעויות ולבסס אמון במודל. בעץ החלטה, תכונה זו באה לידי ביטוי במבנה ההיררכי שלו, המאפשר לעקוב אחר המסלול שהוביל להחלטה.

העץ שהתקבל:

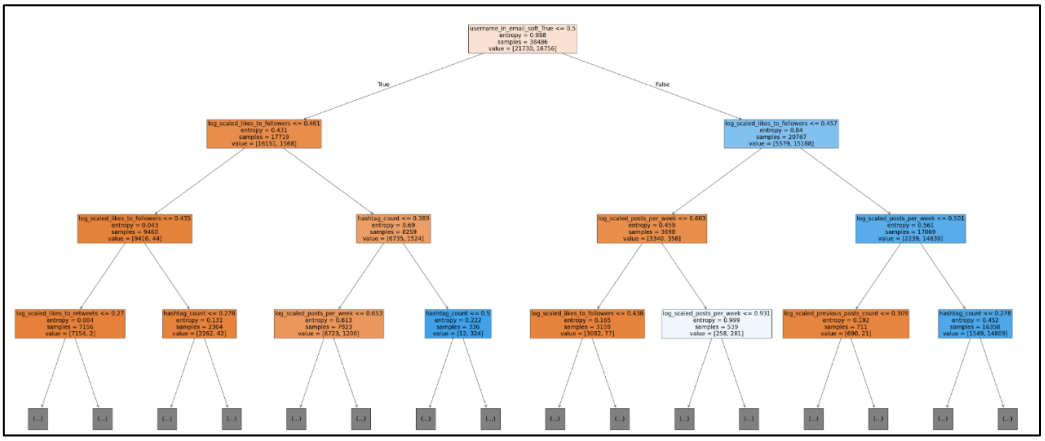

חשיבות הפיצ'רים:

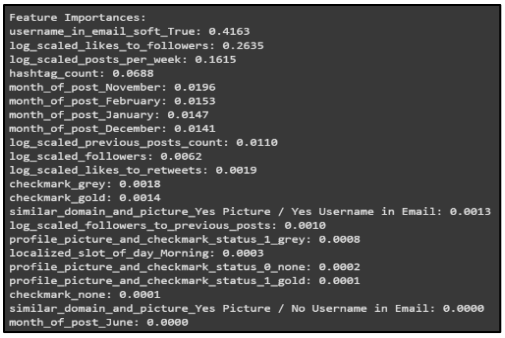

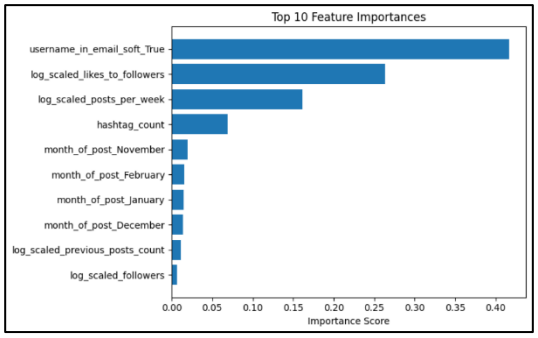

גרף עץ ההחלטה מצביע על כך שהמודל מבסס את החלטותיו בעיקר על פיצ'רים התנהגותיים הקשורים לפעילות המשתמש ולמעורבות העוקבים. בצומת השורש נמצא הפיצ'ר username_in_email_soft_True, המעיד על חשיבותו המכרעת. גם פיצ'רים כמו log_scaled_likes_to_followers ו-log_scaled_posts_per_week מופיעים בענפים מרכזיים. ניתוח חשיבות הפיצ'רים מאשש זאת שכן אותם פיצ'רים מובילים גם בדירוג הכמותי. הלימה זו בין מבנה העץ לבין תרומת הפיצ'רים מחזקת את אמינות המודל. לעומת זאת, פיצ'רים כמו month_of_post_June וסוג החשבון נמצאו בעלי השפעה זניחה.

1.2. Artificial Neural Networks

א. אימון מודל MLP עם ערכי ברירת מחדל:

מודל ה- ANN שנבחר הוא מסוג MLPClassifier מתוך ספריית scikit-learn. ברירת המחדל של המודל כוללת שכבת קלט בגודל מספר הפיצ'רים (במקרה שלנו 22), שכבה חבויה אחת עם 100 נוירונים, ופונקציית אקטיבציה מסוג relu. שכבת הפלט מבצעת סיווג בינארי באמצעות פונקציית איבוד לוגיסטית (log_loss), המתאימה לחיזוי הסתברות. תהליך האימון בוצע באמצעות אלגוריתם אופטימיזציה מסוג Adam עם max_iter=100. המודל הבסיסי אומן באמצעות 10-Fold Cross-Validation והשיג תוצאות AUC ממוצע של 0.9904 על סט האימון ו-0.9887 על סט הוולידציה. הקרבה בין התוצאות מצביעה על כך שהמודל אינו סובל מ- overfitting ומשקף הפרדה ברורה בין הקלאסים גם על נתונים שלא נצפו במהלך האימון.

```
Average AUC Scores:
Mean AUC on Training Set:   0.9904
Mean AUC on Validation Set: 0.9887
```

ב. ההיפרפרמטרים שבחרנו לכוון:

Hidden_layer_sizes: פרמטר זה מגדיר את מבנה הרשת, כלומר, כמה שכבות חבויות יש וכמה נוירונים בכל שכבה. כיוון של הפרמטר יכול לסייע להתאמת המורכבות של המודל. הגדלת מספר השכבות והנוירונים מאפשרת לרשת לתפוס דפוסים מורכבים יותר בדאטה, אך עלולה גם להוביל ל overfitting. לעומת זאת, שימוש במבנה פשוט יותר עשוי להגביל את יכולת הלמידה של המודל, במיוחד כאשר קיימים קשרים מורכבים בין הפיצ'רים. טווח הערכים שנבדק: (100,), (50,), (100, 50)

Learning_rate_init: פרמטר זה מגדיר את גודל הצעד שהמודל מבצע בעת עדכון המשקלים במהלך האימון. ערך נמוך מדי יגרום לכך שהאימון יתקדם באיטיות רבה, ולעיתים אף עלול להיתקע במינימום מקומי מבלי להגיע לפתרון טוב. לעומת זאת, ערך גבוה מדי עלול לגרום לתנודתיות רבה בתהליך הלמידה, כך

שהמודל "יקפוץ" מעל פתרונות טובים ולא יתכנס בכלל. בחרנו לבדוק את הערכים 0.001 ו־0.01 מכיוון שהם ערכים נפוצים באימון רשתות ומאפשרים איזון בין יציבות למהירות הלמידה.

Activation: פרמטר זה מגדיר את פונקציית האקטיבציה שמופעלת על כל נוירון, והיא משפיעה על הדרך שבה הרשת מעבדת מידע ולומדת דפוסים מורכבים. הפונקציה חיונית במיוחד ללמידת קשרים שאינם ליניאריים בין הפיצ'רים. בחנו את הפונקציות relu ו־tanh: הראשונה יעילה בפועל ברשתות עמוקות ומתאפיינת בפשטות חישובית, בעוד השנייה מאפשרת קידוד של קלטים חיוביים ושליליים ומעודדת סימטריה סביב האפס.

תהליך כיוונון ההיפרפרמטרים בוצע באמצעות Grid Search בשילוב Cross-Validation עם max_iter=100, על מנת לאתר את שילוב הערכים האופטימלי באופן שיטתי ומבוקר. לאחר כיוונון ההיפרפרמטרים התקבלה הטבלה הבאה:

Grid Search Summary:

hidden_layer_sizes	learning_rate_init	activation	val_auc	rank
(100, 50)	0.001	tanh	0.990304	1
(50,)	0.010	relu	0.989707	2
(100, 50)	0.001	relu	0.989502	3
(100,)	0.010	relu	0.989022	4
(50,)	0.010	tanh	0.989022	5
(100,)	0.010	tanh	0.988755	6
(100,)	0.001	relu	0.988702	7
(100, 50)	0.010	tanh	0.988250	8
(50,)	0.001	relu	0.987724	9
(100, 50)	0.010	relu	0.987591	10
(100,)	0.001	tanh	0.985914	11
(50,)	0.001	tanh	0.985896	12

מהטבלה ניתן לראות כי הקונפיגורציות שהובילו לביצועים הגבוהים ביותר כללו שתי שכבות חבויות (100, 50) ופונקציית אקטיבציה מסוג tanh. בנוסף, ערך של learning_rate_init=0.001 הוביל לתוצאות יציבות וטובות יותר מערך 0.01 ברוב המקרים. הפערים בין הקונפיגורציות השונות קטנים יחסית, אך ניתן לזהות עדיפות למבנים עמוקים ולפונקציות אקטיבציה שמאפשרות הבחנה בין ערכים חיוביים לשליליים.

במודל המדויק ביותר התקבלו תוצאות AUC ממוצעות של 0.9922 על סט האימון ו-0.9903 על סט הוולידציה. בהשוואה למודל הבסיסי (שבו התקבלו 0.9904 באימון ו־ 0.9887 בוולידציה), ניתן לראות שיפור קל אך עקבי בשני המדדים. שיפור זה מעיד על כך שכיוונון ההיפרפרמטרים תרם לדיוק וליכולת ההכללה של המודל, וניתן לקשור אותו לבחירה נכונה של מבנה הרשת (שתי שכבות חבויות), פונקציית האקטיבציה (tanh) וקצב הלמידה (0.001), אשר הובילו לאיזון טוב יותר בין עומק המודל ויציבות הלמידה.

```
Average AUC Scores:
Mean AUC on Training Set:   0.9922
Mean AUC on Validation Set: 0.9903
```

ג. גרף ביצועים של המודל:

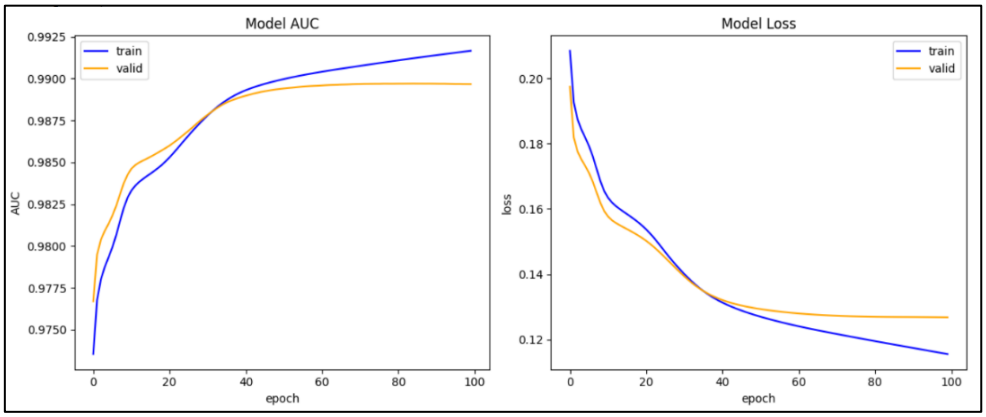

בהתבסס על הגרפים שהתקבלו, ניתן לראות כי המודל מתכנס בצורה יציבה. מדד ה-AUC עלה באופן עקבי לאורך האפוקים והתייצב סביב epoch 40-50, כאשר הפער בין סט האימון לסט הוולידציה נשמר קטן. במקביל, פונקציית ה־ Loss המשיכה לרדת בשני הסטים, אך בוולידציה נרשמה התייצבות סביב epoch 50 מה שמעיד על האטה בקצב השיפור. לאור זאת, ניתן לקבוע כי epoch 50 הוא נקודת עצירה מתאימה, המאזנת בין שיפור בביצועים לבין מניעת overfitting וזמן ריצה מיותר.

SVM .1.3

מטרתו העיקרית של מודל ה-SVM היא לזהות את מישור ההפרדה שמפריד בצורה אופטימלית בין המחלקות בנתונים. מאחר והנתונים כוללים 22 פיצ'רים, מדובר במרחב בעל מימד גבוה ולכן לא ניתן לדמיין או להציג את מישור ההפרדה באופן חזותי.

לצורך כיוונון ההיפר פרמטרים במודל בדקנו את הפרמטרים loss ו-C. הפרמטר C שולט על עוצמת הרגולריזציה של המודל - ערך נמוך מאפשר מודל פשוט וסלחני לטעויות, בעוד ערך גבוה מעניש יותר על שגיאות ומאפשר התאמה חזקה יותר לנתונים. הפרמטר loss קובע את פונקציית ההפסד, hinge: היא הפונקציה הקלאסית של SVM, בעוד squared hinge מענישה שגיאות גדולות באופן חזק יותר. תהליך הכיוונון בוצע באמצעות שיטת ה-grid search ו-cross validation כאשר מדד ההשוואה הוא AUC.

הקונפיגורציות הבאות נבדקו להיפרפרמטרים:

'C': [0.01, 0.1, 1, 10, 100, 1000] 'loss': ['hinge', 'squared_hinge']

הקונפיגורציה שנבחרה כטובה ביותר הייתה: C = 10, loss = 'squared_hinge'.

```
Average AUC Scores:
Mean AUC on Training Set:   0.9792
Mean AUC on Validation Set: 0.9791
```

תחת קונפיגורציה זו, התקבלו תוצאות AUC של 0.9792 על סט האימון ו־0.9791 בממוצע על קבוצות הוולידציה - תוצאה המעידה על הפרדה יציבה בין הקלאסים וללא סימנים של overfitting.

משוואת ההפרדה של המודל הטוב ביותר היא מהצורה w·x + b = 0 כאשר כל מקדם wi מייצג את תרומתו של הפיצ'ר ה־ i לסיווג.

מהניתוח עולה כי ישנם פיצ'רים בעלי השפעה בולטת יותר על תהליך הסיווג. מקדמים חיוביים מצביעים על נטייה לסווג את הדוגמה לאחת הקטגוריות, בעוד שמקדמים שליליים מרמזים על השפעה המובילה לכיוון הקטגוריה השנייה. מידע זה מאפשר להבין כיצד כל פיצ'ר תורם להחלטות שהמודל מקבל. ניתן לראות כי גם מודל ה- SVM וגם עץ ההחלטה מצביעים על אותם פיצ'רים כמשמעותיים במיוחד עבור משימת הסיווג, דבר שמעיד על עקביות בין המודלים ועל חשיבותם האמיתית של משתנים אלו.

משוואת הישר:

```
month_of_post_January: -0.8874
month_of_post_February: -0.8525
checkmark_grey: 0.4982
checkmark_gold: 0.4417
profile_picture_and_checkmark_status_1_gold: 0.0573
profile_picture_and_checkmark_status_1_grey: 0.0507
checkmark_none: 0.0057
profile_picture_and_checkmark_status_0_none: -0.0656
month_of_post_June: -0.0088
localized_slot_of_day_Morning: 0.1769
Intercept (bias): -3.2781
```

```
username_in_email_soft_True: 0.9963
similar_domain_and_picture_Yes Picture / Yes Username in Email: 0.0513
log_scaled_posts_per_week: 2.1032
hashtag_count: 1.8334
log_scaled_likes_to_followers: 2.9998
similar_domain_and_picture_Yes Picture / No Username in Email: -0.1135
log_scaled_followers_to_previous_posts: -0.9210
log_scaled_likes_to_retweets: 0.0427
log_scaled_previous_posts_count: -0.3974
log_scaled_followers: 0.6930
month_of_post_December: -0.8901
month_of_post_November: -0.8851
```

1.4. Clustering

א. שיטת ניתוח אשכולות לעומת מודלים קודמים:

בניגוד למודלים הקודמים שהתבססו על למידה מונחית עם תוויות סנטימנט, Clustering הוא תהליך של למידה לא מונחית, כלומר, אין שימוש במשתנה המטרה. המטרה כאן אינה לחזות סנטימנט, אלא לבדוק האם קיימת חלוקה טבעית בנתונים שיכולה להתאים לסנטימנטים או לחשוף תבניות נסתרות.

לצורך ביצוע ניתוח אשכולות, נבחרו שישה פיצ'רים המייצגים מגוון רחב של מאפיינים התנהגותיים של המשתמשים. המטרה בבחירה זו הייתה לזהות תבניות כלליות בין המשתמשים, מבלי להניח מראש קיומן של קבוצות מוגדרות או להסתמך על תוויות סנטימנט ועל Fisher Score. הפיצ'רים שנבחרו הם:

פיצ'ר	תיאור קצר	משמעות אפשרית למשימת הלמידה
log_scaled_posts_per_week	מדד לפעילות כוללת של המשתמש	הבחנה בין משתמשים פעילים לבין לא פעילים
log_scaled_likes_to_followers	יחס לייקים לעוקבים	מדד למידת המעורבות של העוקבים
log_scaled_followers_to_previous_posts	יחס בין עוקבים לתוכן קודם שפורסם	מאפשר זיהוי משתמשים משפיעים או בולטים
similar_domain_and_picture - Yes Picture / No Username in Email	שילוב אינדיקציות לאותנטיות	משמש כמדד לאמינות הפרופיל
localized_slot_of_day_Morning	האם הפוסט פורסם בבוקר	עשוי לשקף סגנון חיים או דפוס פעילות

השימוש במאפיינים התנהגותיים מאפשר להפעיל אלגוריתם Clustering על בסיס פרופילים שלמים ועשירים, ולגלות דפוסים סמויים של דמיון בין משתמשים שלאו דווקא באים לידי ביטוי באופן מיידי בתוויות סנטימנט. לצורך חישוב הדמיון בין משתמשים וביצוע Clustering על בסיס מאפיינים מגוונים, נעשה שימוש במטריקת Gower Distance. מטריקה זו נועדה לטפל במקרים בהם הנתונים כוללים משתנים מסוגים שונים (מספריים, בינאריים וקטגוריקליים) ולכן מתאימה במיוחד לדאטה שבידינו. **הערה חשובה: מאחר שחישוב מרחק Gower דורש משאבי זיכרון גבוהים, ביצענו את הניתוח על מדגם מייצג של 4,000 תצפיות**

(כ- 10% מכלל הנתונים). השימוש ב- Gower איפשר לנו לזהות טיפוסי משתמש מגוונים, בפרט כאלו שאינם נבדלים רק בפיצ'רים מספריים, ולכן למרות המגבלה החלטנו להשתמש בשיטה זו.

הפיצ'רים ששימשו ל- Clustering נבחרו מתוך תהליך Feature Selection שהתבסס על ציוני Fisher ביחס למשתנה המטרה (sentiment) ולכן ייתכן שיש ביניהם קשר מסוים לתוויות הקיימות. משמעות הדבר היא שהאשכולות שהתקבלו עשויים לשקף חלקית את חלוקת הרגש, גם אם לא זו הייתה הכוונה הישירה. אידיאלית, היה ניתן לשקול שילוב של פיצ'רים שנבחרו לפני שלב הסלקציה, במטרה לחשוף דפוסים כלליים או טיפוסים בלתי תלויים בתוצאה, וכך להפיק תובנות התנהגותיות נוספות על המשתמשים.

ב. השוואת תוצאות האישכול עבור ערכי K שונים:

תוצאות עבור סט הפיצ'רים שבחרנו (ימין) לעומת כל הפיצ'רים ב- dataset (שמאל):

```
K=2 --> Silhouette Score = 0.3614
K=3 --> Silhouette Score = 0.2142
K=4 --> Silhouette Score = 0.1809
K=5 --> Silhouette Score = 0.1623
K=6 --> Silhouette Score = 0.1587
```

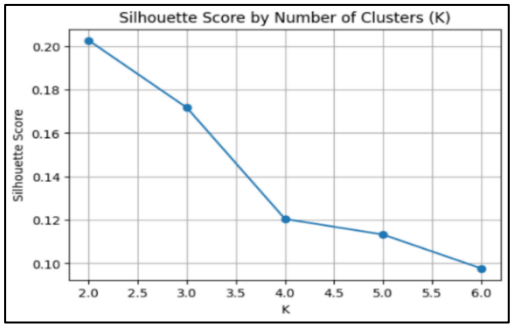


```
K=2 --> Silhouette Score = 0.2027
K=3 --> Silhouette Score = 0.1717
K=4 --> Silhouette Score = 0.1204
K=5 --> Silhouette Score = 0.1132
K=6 --> Silhouette Score = 0.0976
```

שני סטים של פיצ'רים נבחנו: סט מצומצם וכלל הפיצ'רים. מדד ה- Silhouette הראה כי K=2 הוא מספר האשכולות האופטימלי בשני המקרים, אך איכות האשכולות הייתה גבוהה יותר בשימוש בכל הפיצ'רים, מה שמרמז על תרומה של פיצ'רים שלא נבחרו מראש. מדדים נוספים לא חושבו בשל השימוש במרחק Gower, שאינו תומך במרחק אוקלידי. נמצא קשר חלקי בין האשכולות למשתנה הסנטימנט, ככל הנראה בשל פיצ'רים שנבחרו לפי קשר מוקדם אליו.

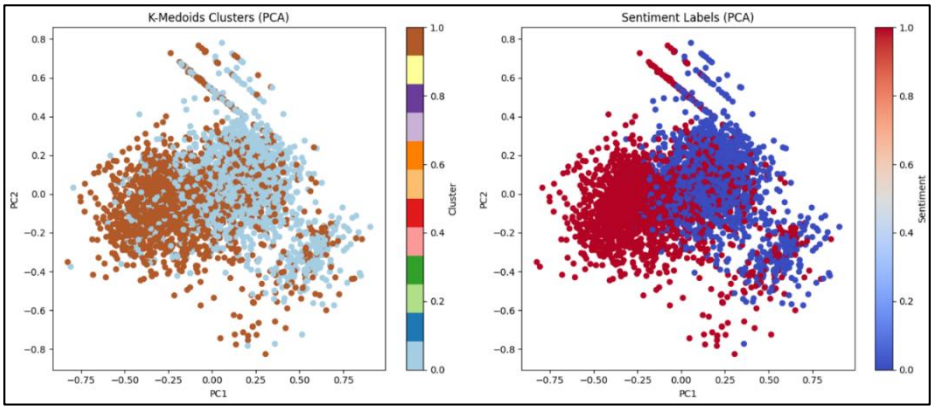

לצורך ויזואליזציה של האשכולות, בוצעה הפחתת ממד באמצעות PCA לשני רכיבים עיקריים, לאחר סינון הפיצ'רים למשתנים מספריים בלבד. התרשימים מציגים את התצפיות לפי שיוך לאשכולות (משמאל) ולפי תוויות הסנטימנט האמיתיות (מימין). נראית חפיפה חלקית בין הקבוצות, שמעידה כי האשכולות משקפים גם את מבנה הסנטימנט, למרות שהמודל לא אומן עליו, וכן תכונות התנהגותיות כלליות נוספות.

2. Evaluation

א. בחירת המודל:

מודל	AUC – אימון	AUC – ולידציה
DT	0.99	0.9862
SVM	0.9792	0.9791
MLP	0.9922	0.9903

השוואה בין ביצועי שלושת מודלי הסיווג (DT, SVM, MLP): למרות שמודל ה-MLP השיג את התוצאה הגבוהה ביותר במדדי ה-AUC, בחרנו להמליץ על מודל עץ ההחלטה (DT) כמודל הסיווג המועדף. ההפרשים בין המודלים מבחינת AUC היו זניחים יחסית (פחות מאחוז), ולכן ניתן היה לשלב שיקולים נוספים בבחירה. כפי שנזכר לעיל, מודל DT מציע יכולת פרשנות (interpretability) גבוהה, ובכך מאפשר להבין את תהליך קבלת ההחלטות בצורה שקופה. יכולת זו חשובה במיוחד כאשר המודל מיועד לשמש ככלי תומך החלטה בתחומים רגישים, כמו סיווג סנטימנט, בהם נדרשת explainability. יתרונות נוספים כוללים פשטות חישובית, מהירות אימון והרצה, והטמעה קלה. עם זאת, למודל עץ ההחלטה קיימות מגבלות. הוא עלול להיות רגיש לרעש בנתונים או לשינויים קטנים, תופעה שעלולה להוביל ל-overfitting. כמו כן, הוא מתקשה בזיהוי קשרים לא ליניאריים מורכבים או אינטראקציות בין משתנים, יכולת שמודלים כמו MLP מצליחים בה יותר. לכן, כאשר קיימים קשרים לא ליניאריים עדינים בין פיצ'רים, מודל עץ ההחלטה עשוי לא לזהות את הדפוס המורכב, ולפיכך לתת תחזיות פחות מדויקות. במקרה כזה, ייתכן שמודל כמו MLP יפיק תוצאות טובות יותר.

ב. ניתוח ויזואלי של ביצוע המודל:

לצורך קביעת נקודת הסף, נעשה שימוש בעקומות ROC בכל אחד מ-10 הקיפולים של CV. הסף נבחר לפי קריטריון של Specificity של לפחות 95%, ככל האפשר, במטרה לצמצם את שיעור ה-False Positives ולמנוע זיהוי שגוי של מקרה שלילי כמקרה חיובי, כלומר, סנטימנט שלילי שלא מזוהה. שגיאה כזו עלולה להוביל להתעלמות ממקרים חשובים שדורשים התערבות, ולכן הוגדרה כקריטית. הבחירה נשענה גם על עקומות ROC כדי לשמור על Specificity גבוהה, ואכן המודל הציג ערכי AUC של מעל 0.98 בכל הקיפולים. ערכי הסף שנבחרו מסומנים בצהוב בפלט המצורף.

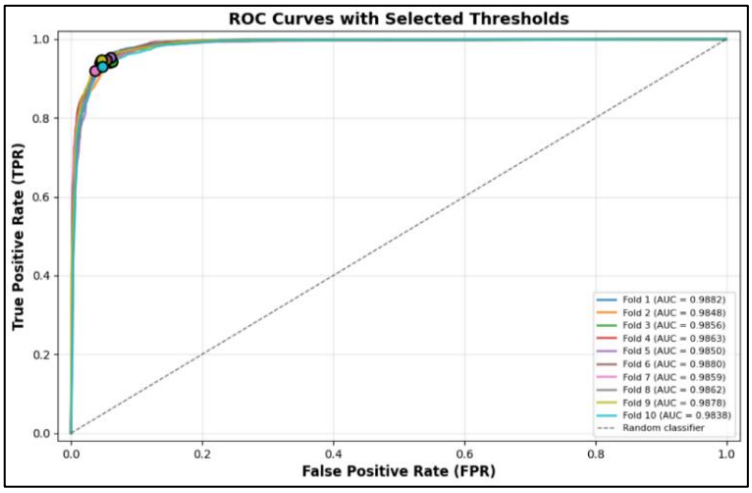

DETAILED RESULTS

Fold	AUC	Accuracy	Specificity	Sensitivity	Precision	Threshold	FPR	TPR
1	0.9882	0.9436	0.9503	0.9350	0.9355	0.600000	0.0497	0.9350
2	0.9848	0.9431	0.9411	0.9457	0.9253	0.647059	0.0589	0.9457
3	0.9856	0.9449	0.9420	0.9487	0.9266	0.626506	0.0580	0.9487
4	0.9863	0.9457	0.9512	0.9385	0.9369	0.641509	0.0488	0.9385
5	0.9850	0.9454	0.9397	0.9529	0.9242	0.585443	0.0603	0.9529
6	0.9880	0.9496	0.9508	0.9481	0.9369	0.621622	0.0492	0.9481
7	0.9859	0.9389	0.9581	0.9140	0.9439	0.567901	0.0419	0.9140
8	0.9862	0.9485	0.9549	0.9403	0.9414	0.600000	0.0451	0.9403
9	0.9878	0.9519	0.9590	0.9427	0.9466	0.533333	0.0410	0.9427
10	0.9838	0.9420	0.9475	0.9349	0.9321	0.551724	0.0525	0.9349

SUMMARY STATISTICS

```
Validation AUC: Mean=0.9862 ± 0.0014
Specificity: Mean=0.9495 ± 0.0065
Sensitivity: Mean=0.9401 ± 0.0104
Accuracy:    Mean=0.9454 ± 0.0036
FPR:         Mean=0.0505 ± 0.0065
TPR:         Mean=0.9401 ± 0.0104
Threshold:   Mean=0.5975 ± 0.0361
```

מטריצת הבלבול המצרפית הצביעה על איזון בין המחלקות, עם שיעור זיהוי נכון של 94% לחיוביים ו-94.9% לשליליים, ופער קטן בין סוגי הטעויות (FPR של 5.1% מול FNR של 6.0%). ממצאים אלו תומכים בכך שאין הטיה מובהקת כלפי אחת המחלקות.

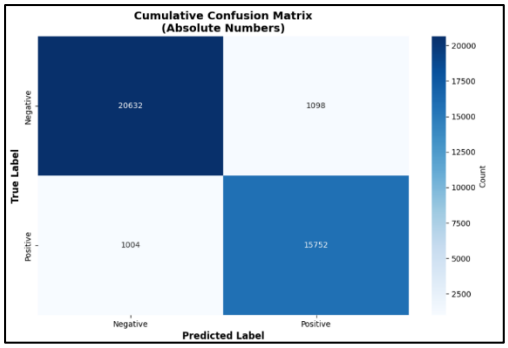

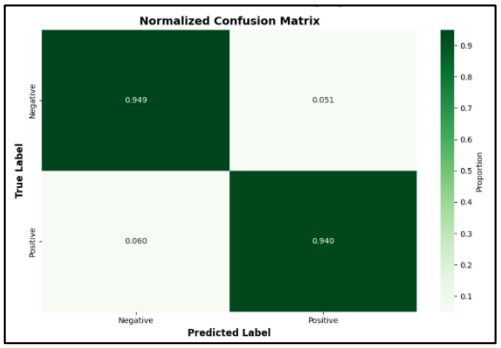

ג. סיכום:

בהשוואת חשיבות הפיצ'רים בין מודל עץ החלטה ל-SVM, ניתן לראות עקביות בפיצ'רים הבולטים ביותר, מה שמעיד על תרומתם הגבוהה למשימת הסיווג: username_in_email_soft_True, log_scaled_likes_to_followers ו- log_scaled_posts_per_week. עם זאת, הסתמכות רבה על מאפיינים אלו עלולה ליצור הטיה כלפי מחלקה מסוימת. לדוגמה, העדפה לזיהוי פרופילים פעילים ומובחנים, תוך קושי בזיהוי פוסטים מורכבים יותר. כמו כן, כפי שצוין לעיל, ממצאי מטריצת הבלבול תומכים בכך שאין הטיה מובהקת כלפי אחת המחלקות.

במהלך האימון זיהינו סימן אפשרי ל-Overfitting במודל עץ ההחלטה, כאשר נצפה פער קטן בין ביצועי האימון (AUC = 0.99) לוולידציה (AUC = 0.9862). כדי להתמודד עם כך, יישמנו גיזום (Pruning) בעזרת הגבלת עומק העץ וכמות הדגימות לפיצול, מה שסייע להפחית מורכבות ולשפר את ההכללה. בנוסף, ניתן לשקול שימוש ב-Random Search כתחליף ל-Grid Search, כדי לבחון אפשרויות מגוונות באופן אקראי, ובכך לזהות גם מודלים פשוטים יותר עם ביצועים טובים.

3. Improvements

סעיפים א' + ב':

אחת האפשרויות המרכזיות לשיפור בשלב עיבוד הנתונים היא שיפור תהליך השלמת הערכים החסרים. כרגע, ההשלמה מתבצעת על פי התפלגות ההסתברות של הקטגוריות במשתנים הקטגוריאליים ובאמצעות חציון במשתנים הנומריים. עם זאת, קיימות שיטות מתקדמות ומדויקות יותר, כמו KNNImputer אשר מאפשרת השלמה חכמה על סמך דמיון לדגימות אחרות. שיטה זו מתחשבת בכלל הפיצ'רים הקיימים בדגימה החלקית ומשווה אותה לדגימות אחרות בדאטה בהן לא חסר הערך באותו הפיצ'ר, כדי למצוא את השכנים הקרובים ביותר לפי מדדי דמיון נומריים. לאחר מכן, היא משערת את הערך החסר על פי הממוצע של אותם שכנים. כך במקום להשלים ערכים חסרים בצורה סטטית ואחידה, ההשלמה מותאמת לדפוסים הקיימים

בדאטה. חשוב לציין ש- KNNImputer פועל רק על משתנים נומריים ולכן את הטיפול במשתנים הקטגוריקליים נשאיר כמו שהוא.

אחד השיפורים האפשריים למודל הוא מעבר ממודל של עץ החלטה בודד למודל אנסמבלי מסוג Random Forest. בשיטה זו מספר רב של עצי החלטה נבנים על תתי-מדגמים שונים של הדאטה, כאשר כל עץ נחשף רק לחלק מהפיצ'רים בכל פיצול. התחזית הסופית מתקבלת באמצעות הצבעה של כל העצים (Voting). שיטה זו מצמצמת את ההשפעה של טעויות מקומיות של עץ יחיד, מקטינה את הסיכון ל-Overfitting ומביאה לשיפור ביכולת ההכללה (generalization) של המודל.

ג. מימוש הרעיונות וניתוח התוצאות:

מימשנו את ההצעות לשיפור שהבאנו ועברנו ממודל עץ החלטה למודל Random Forest ובשלב עיבוד הנתונים השתמשנו ב KNNImputer. יישמנו Random search ו-cross validation כאשר מדד ההשוואה הוא ROC-AUC על ההיפר פרמטרים הבאים:

- n_estimators - מספר העצים ביער (נבדקו: 50, 100, 200)
- max_depth - עומק מרבי לכל עץ (None, 5, 10, 20)
- min_samples_split - מספר מינימלי של דגימות לצורך פיצול (2, 5, 10)
- max_features - מספר הפיצ'רים שנשקלים בכל פיצול ('sqrt', 'log2')

בתום החיפוש התקבלו ההיפר פרמטרים האופטימליים הבאים:

```
Best Parameters:
{'randomforestclassifier__n_estimators': 200, 'randomforestclassifier__min_samples_split': 10,

 'randomforestclassifier__max_features': 'sqrt', 'randomforestclassifier__max_depth': 20}
```

ד. מדדי המודל המשופר:

התקבלו תוצאות AUC ממוצע של 0.9985 על סט האימון ו- 0.99 על סט הווליידציה. תוצאות אלו מצביעות על שיפור לעומת מודל עץ ההחלטה, שבו התקבלו ערכי AUC של 0.99 באימון ו- 0.9862 בווליידציה.

```
Average AUC Scores:
Train AUC: 0.9985 (99.85%)
Validation AUC: 0.9900 (99.00%)
```

4. Test

כנדרש, הועלה קובץ עם החיזויים של המודל המשופר על סט הבדיקה.